Laboratorio #2

Presentado por

Cristian Ballen Gamboa Breyner Andreit Rincon Quiroga

Documentación

#1 Ejecución del archivo #2

- Tiempo 27 segundos
- ram 4.7 gb

```
import pandas as pd
# flights_file1 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2018.parquet"
flights_file2 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2019.parquet"
# flights_file3 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2020.parquet"
# flights_file4 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
# flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
# df1 = pd.read_parquet(flights_file1)
df2 = pd.read_parquet(flights_file2)
# df3 = pd.read_parquet(flights_file3)
# df4 = pd.read_parquet(flights_file4)
# df5 = pd.read_parquet(flights_file5)
```

#2 Ejecución del archivo #3

- Tiempo 14 segundos
- Ram 3.6 gb

```
import pandas as pd

# flights_file1 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2018.parquet"

# flights_file2 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2019.parquet"

flights_file3 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2020.parquet"

#flights_file4 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"

#flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2022.parquet"

# flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2022.parquet"

# df1 = pd.read_parquet(flights_file1)

# df2 = pd.read_parquet(flights_file3)


# df4 = pd.read_parquet(flights_file4)

# df5 = pd.read_parquet(flights_file5)
```

RAM del sistema	Disco
3.6 / 12.7 GB	28.1 / 107.7 GB


#3 Ejecución del archivo #4

- Tiempo 13 segundos
- Ram 4.2 gb



#4 Ejecución del archivo #5

- Tiempo 4 segundos
- Ram 3.2 gb



#5 concatenación del archivo 2 y 3 nos deja visualizar que la Ram no tiene suficiente espacio para realizar la ejecución y sólo se podrá ejecutar un archivo.

6 Al realizar la concatenación del archivo 3 y 5 podemos visualizar que la ram cuenta con espacio suficiente para concatenar estos dos archivos, , (dependiendo el tamaño del archivo solo se podrá ejecutar si la ram tiene espacio suficiente).

Debido a que el archivo 3 y 5 nos ayuda a evidenciar que podemos realizar la concatenación de los dos archivos, realizaremos el ejercicio con este ejemplo.

```
# flights_file1 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2018.parquet"
# flights_file2 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2019.parquet"
flights_file3 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2020.parquet"
# flights_file4 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
# df1 = pd.read_parquet(flights_file2)
df3 = pd.read_parquet(flights_file3)
# df4 = pd.read_parquet(flights_file4)
df5 = pd.read_parquet(flights_file5)

# df = pd.concat([df3, df5])
# df = pd.concat([df3, df5])
# df = df2
```



El código agrupa los datos de vuelo por aerolínea y año, calcula varias estadísticas sobre los retrasos en la salida y llegada, luego guarda los resultados agrupados y calculados en un archivo Parquet llamado "temp" pandas.parquet".

```
# %%timeit

df_agg = df.groupby(['Airline','Year'])[["DepDelayMinutes", "ArrDelayMinutes"]].agg(
....["mean", "sum", "max"]
)


df_agg = df_agg.reset_index()
df_agg.to_parquet("temp_pandas.parquet")
```

Se evidencia que la ejecución del código se demora 2 segundos.

```
!ls -GFlash temp_pandas.parquet

12K -rw-r--r-- 1 root 10K Jun 20 00:19 temp_pandas.parquet
```

lista detalladamente el archivo temp_pandas.parquet en el directorio actual. se visualiza la informacion




carga el archivo Parquet temp_pandas.parquet en un DataFrame utilizando pd.read_parquet(), y luego llama al método .info() en ese DataFrame para imprimir un resumen de la estructura y la información básica

```
↑ ↓ ⇔ 🗏 💠 🖟 🔟
   pd.read_parquet('temp_pandas.parquet').info() ?
<<class 'pandas.core.frame.DataFrame'>
    RangeIndex: 47 entries, 0 to 46
    Data columns (total 8 columns):
                                 Non-Null Count Dtype
        Column
         (Airline, )
                                 47 non-null
         (DepDelayMinutes, mean) 47 non-null
                                                float64
         (DepDelayMinutes, sum)
                                 47 non-null
                                                float64
         (DepDelayMinutes, max)
                                 47 non-null
                                                float64
         (ArrDelayMinutes, mean) 47 non-null
                                                float64
         (ArrDelayMinutes, sum)
                                47 non-null
                                                float64
         (ArrDelayMinutes, max)
                                 47 non-null
    dtypes: float64(6), int64(1), object(1)
    memory usage: 3.1+ KB
```

Pandas

Con Pandas logramos evidenciar que el uso de Ram (11.8) y el tiempo (63 segundos).




Polars

Con polars se evidencia que el uso de Ram (1.3gb) y de tiempo (9 segundos).



PySpark

Con pyspark logramos evidenciar que el uso de Ram (2.0) y el tiempo (75 segundos)



dask

Con dask logramos evidenciar que el uso de Ram (7.2) y el tiempo (50 segundos)


```
    Playing with dask

                                                                                                                                                                                                                                                       Aceptar
                                                                                                                                                                                               No te has suscrito. Más información
import pandas as pd
import dask.dataframe as dd
# flights_file1 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2018.parquet"
# flights_file1 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2019.parquet"
flights_file3 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2019.parquet"
flights_file4 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
# flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
# flights_file5 = "/content/drive/MyDrive/big data/flights/Combined_Flights_2021.parquet"
# df1 = dd.read_parquet(flights_file1)
# df2 = dd.read_parquet(flights_file2)
df3 = dd.read_parquet(flights_file3)
df4 = dd.read_parquet(flights_file4)
# df5 = dd.read_parquet(flights_file5)
                                                                                                                                                                                               En estos momentos, no tienes ningunu que se ofrecen sin coste económico no están garantizados. Puedes comprar más
                                                                                                                                                                                               Con tu nivel de uso actual, puede que este entorno de ejecución dure hasta 27 horas
                                                                                                                                                                                               minutos.
                                                                                                                                                                                              ¿Quieres más memoria y espacio en disco? Pasarse a Colab Pro
                                                                                                                                                                                               del backend de Google Compute Engine que utiliza Python 3
Mostrando recursos desde las 19:17 a las 19:50
) [3] df = dd.concat([df3, df4])
                                                                                                                                                                                                                            Disco
29.2 / 107.7 GB
[4] print(df.compute())
                      FlightDate
2020-09-01
2020-09-02
2020-09-03
2020-09-04
2020-09-05
                                                             Airline Origin Dest
air Inc. PHL DAY
                                                                                                           Diverted
False
False
False
                                                       Comair Inc.
Comair Inc.
Comair Inc.
Comair Inc.
Comair Inc.
                                                                                                 False
False
False
           573774 2021-06-01 Southwest Airlines Co.
573775 2021-06-01 Southwest Airlines Co.
573776 2021-06-01 Southwest Airlines Co.
573777 2021-06-01 Southwest Airlines Co.
573778 2021-06-01 Southwest Airlines Co.
                                                                                    MDW
MDW
MIA
MIA
MKE
                                                                                                 False
False
False
False
False
                                                                                                               False
False
False
False
False
                                                                             BNA
BNA
BNA
BNA
                       DepDelay
-7.0
-7.0
-10.0
-8.0
-9.0
                                                                                                    WheelsOff \
                                                                                                         1914.0
                                                                                                         1914.0
                                1255 1301.0
                                                                                                         1310.0
                                                                                                                                                                                               Cambiar tipo de entorno de ejecución
√ [5] df = df.compute()
 √
1s [6] # %%timeit
                    df_agg = df.groupby(['Airline','Year'])[["DepDelayMinutes", "ArrDelayMinutes"]].agg(
                            ["mean", "sum", "max"]
                    df_agg = df_agg.reset_index()
                    df_agg.to_parquet("temp_dask.parquet")
 √ [7] !ls -GFlash temp_pandas.parquet

→ 12K -rw-r--r-- 1 root 10K Jun 20 00:19 temp_pandas.parquet


 v [8] pd.read_parquet('temp_dask.parquet').info()
          <class 'pandas.core.frame.DataFrame'>
                    RangeIndex: 47 entries, 0 to 46
                   Data columns (total 8 columns):
                                                                                      Non-Null Count Dtype
                     # Column
                     a
                               (Airline, )
                                                                                      47 non-null
                                                                                                                          string
                     1
                               (Year, )
                                                                                      47 non-null
                                                                                                                          int64
                              (DepDelayMinutes, mean) 47 non-null
(DepDelayMinutes, sum) 47 non-null
                                                                                                                          float64
                                                                                                                          float64
                              (DepDelayMinutes, max)
                                                                                                                          float64
                                                                                     47 non-null
                              (ArrDelayMinutes, mean) 47 non-null
                                                                                                                          float64
                   6 (ArrDelayMinutes, sum) 47 non-null
7 (ArrDelayMinutes, max) 47 non-null
dtypes: float64(6), int64(1), string(1)
                                                                                                                          float64
                                                                                                                          float64
                   memory usage: 3.1 KB
```

Recursos X




Resultados

Librería	Ram	Tiempo (Segundos)
Pandas	11.8	63
spark	2.0	75
dask	7.2	50
polar	1.3	9



Logramos evidenciar que polars es significativamente mejor para la lectura de los datos dando mejores resultados en tiempo y uso de ram.

Al visualizar la lectura de los archivos podemos observar que el resultado de pandas, polars y dask son iguales, el único que difiere de resultados es spark, de igual manera los encabezados suelen cambiar según la librería



Conclusión

Según la ejecución de todos los archivos y códigos logramos evidenciar que polars es el que tiene mejor rendimiento, ocupando menos ram y menor tiempo en ejecución.